

LABORATORIUM 3

UCZENIE ZE WZMOCNIENIEM

Q-learning i SARSA w środowisku Cliff Walking

Cel ćwiczenia

Celem laboratorium jest praktyczne poznanie podstaw uczenia ze wzmocnieniem na klasycznym problemie sterowania sekwencją decyzji. Student uruchamia gotowy kod referencyjny, analizuje przebieg uczenia, dostraja parametry algorytmów Q-learning i SARSA, a następnie porównuje uzyskane polityki i formułuje wnioski do raportu.

- zrozumienie pojęć: stan, akcja, nagroda, polityka, epizod, eksploracja i eksploatacja,
- poznanie różnicy między algorytmem off-policy (Q-learning) oraz on-policy (SARSA),
- umiejętność strojenia hiperparametrów: α , γ , ϵ , liczba epizodów, limit kroków,
- samodzielna interpretacja wykresów, polityk oraz metryk jakości.

Wprowadzenie teoretyczne

Uczenie ze wzmocnieniem (reinforcement learning, RL) dotyczy sytuacji, w której agent uczy się poprzez interakcję ze środowiskiem. W odróżnieniu od uczenia nadzorowanego nie otrzymuje gotowych etykiet dla każdej próbki. Zamiast tego obserwuje stan środowiska, wykonuje akcję i otrzymuje nagrodę. Celem jest znalezienie takiej polityki działania, która maksymalizuje łączną nagrodę w długim horyzoncie.

- stan (state) — opis aktualnej sytuacji agenta,
- akcja (action) — decyzja podejmowana przez agenta,
- nagroda (reward) — sygnał jakości podjętej decyzji,
- polityka (policy) — reguła wyboru akcji w danym stanie,
- epizod (episode) — pojedynczy przebieg od stanu początkowego do zakończenia.

Funkcja wartości akcji

W ćwiczeniu wykorzystujemy tablicową aproksymację funkcji $Q(s, a)$, która opisuje oczekiwaną zdyskontowaną sumę nagród po wykonaniu akcji a w stanie s . Dla dyskretnych stanów i akcji przechowujemy wartości w tablicy Q-table. Podczas uczenia wartości są aktualizowane iteracyjnie na podstawie obserwowanego przejścia.

$$\text{Q-learning: } Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

$$\text{SARSA: } Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma Q(s', a') - Q(s, a)]$$

Parametr α (alpha) kontroluje szybkość uczenia, γ (gamma) odpowiada za znaczenie przyszłych nagród, a ϵ (epsilon) steruje kompromisem eksploracja–eksploatacja. W strategii epsilon-greedy z

prawdopodobieństwem ϵ agent wybiera akcję losową, a w przeciwnym przypadku akcję o największej wartości Q .

Q-learning kontra SARSA

Cecha	Q-learning	SARSA
Typ metody	off-policy	on-policy
Intuicja	uczy się względem najlepszej przewidywanej akcji w następnym stanie	uczy się względem akcji faktycznie wybranej przez bieżącą politykę
Typowy efekt w Cliff Walking	częściej wybiera krótszą, ale bardziej ryzykowną ścieżkę blisko klifu	częściej wybiera ścieżkę bezpieczniejszą, zwykle dłuższą

Opis środowiska Cliff Walking

Środowisko ma postać siatki 4×12 . Agent startuje w lewym dolnym rogu (S), a celem jest dojście do pola końcowego (G). Pola między startem i celem w dolnym wierszu tworzą klif. Wejście na klif kończy się dużą karą i powrotem do punktu startowego. Każdy zwykły krok daje niewielką karę, co zachęca agenta do znajdowania krótkich tras.

Liczba stanów	48
Liczba akcji	4: góra, prawo, dół, lewo
Nagroda za zwykły krok	-1
Kara za klif	-100 oraz powrót do startu
Zakończenie epizodu	osiągnięcie celu lub przekroczenie limitu kroków

Zakres zadania laboratoryjnego

1. Uruchom dostarczony plik `3_RL_cliffwalking.py` i sprawdź, jakie pliki wynikowe są zapisywane.
2. Przeanalizuj strukturę kodu: środowisko, funkcje uczące, ewaluację oraz generowanie wykresów.
3. Wykonaj eksperyment bazowy na domyślnych parametrach i zapisz metryki dla obu algorytmów.
4. Dostrój parametry co najmniej w czterech własnych eksperymentach. Zmieniaj pojedyncze parametry lub zestawy parametrów w sposób kontrolowany.
5. Porównaj Q-learning i SARSA pod względem szybkości uczenia, stabilności oraz jakości finalnej polityki.
6. Opisz wnioski: kiedy lepszy jest wariant bardziej zachłanny, a kiedy bezpieczniejszy.

Parametry, które należy stroić

Parametr	Znaczenie	Wartość bazowa	Przykładowy zakres badań
alpha	tempo aktualizacji Q-table	0.10	0.05–0.50
gamma	waga przyszłych nagród	0.95	0.80–0.99
epsilon_start	początkowa eksploracja	1.00	0.60–1.00
epsilon_min	minimalna eksploracja	0.05	0.01–0.10
epsilon_decay	tempo zmniejszania eksploracji	0.995	0.990–0.999
episodes	liczba epizodów uczących	800	400–3000

Instrukcja uruchomienia

Wymagane biblioteki: numpy oraz matplotlib. Środowisko zostało zaimplementowane samodzielnie, dlatego nie trzeba instalować biblioteki gym ani gymnasium.

```
pip install numpy matplotlib
python 3_RL_cliffwalking.py
```

Po uruchomieniu program zapisuje w katalogu wynikowym:


- wykres_uczenia.png — przebieg uczenia dla Q-learning i SARSA,
- polityka_q_learning.png — finalna polityka zachłanna dla Q-learning,
- polityka_sarsa.png — finalna polityka zachłanna dla SARSA,
- metryki.csv — zestawienie metryk i parametrów konfiguracji,
- polityka_q_learning.txt oraz polityka_sarsa.txt — prosta reprezentacja tekstowa polityk.

Najważniejsze fragmenty kodu

- klasa CliffWalkingEnv opisuje stany, akcje, nagrody i reguły przejścia,
- funkcja train_q_learning implementuje algorytm off-policy,
- funkcja train_sarsa implementuje algorytm on-policy,
- evaluate_policy ocenia finalną politykę w trybie zachłannym,
- plot_learning_curves oraz plot_policy przygotowują materiały do raportu.


Przykład wyników referencyjnych

Poniższe rysunki pokazują przykładowy rezultat dla konfiguracji bazowej. Służą jako punkt odniesienia; studenci powinni samodzielnie wykonać własne eksperymenty i sprawdzić, jak zmiana parametrów wpływa na przebieg uczenia oraz strukturę polityki.




Rysunek 1. Przykładowy wykres uczenia dla konfiguracji bazowej.

Dla ustawień bazowych można zaobserwować szybsze zbliżanie się SARSA do stabilnego zachowania, ale finalna ścieżka Q-learning bywa krótsza i bardziej ryzykowna. To dobra baza do dyskusji o różnicy między on-policy i off-policy.



Rysunek 2. Finalna polityka Q-learning — typowo krótsza, bliżej klifu.



Rysunek 3. Finalna polityka SARSA — zwykle bardziej ostrożna.

Wymagania do raportu

- Krótki wstęp teoretyczny: czym jest RL i czym różni się Q-learning oraz SARSA.
- Opis środowiska i sposobu kodowania stanów oraz akcji.
- Tabela eksperymentów z dokładnymi parametrami.
- Co najmniej dwa wykresy i interpretacja zmian w przebiegu uczenia.
- Porównanie finalnych polityk oraz metryk.
- Końcowe wnioski: który algorytm był szybszy, stabilniejszy i bezpieczniejszy.

Tabela do uzupełnienia w raporcie

Eksperyment	Algorytm	alpha	gamma	eps_decay	Śr. nagroda	Śr. kroki	Wniosek
E1							
E2							
E3							
E4							
E5							

Pytania pomocnicze do analizy

- Jak wpływa zwiększenie alpha na szybkość i stabilność uczenia?
- Czy wolniejsze zmniejszanie epsilon poprawia jakość finalnej polityki?
- Który algorytm częściej wybiera trasę blisko klifu i dlaczego?
- Czy większa liczba epizodów zawsze poprawia wyniki? Kiedy pojawia się efekt malejących korzyści?
- Jak zmieniają się wyniki po zwiększeniu lub zmniejszeniu kary za klif?

Kryteria zaliczenia ćwiczenia

- poprawne uruchomienie programu i zrozumienie działania środowiska,
- samodzielne wykonanie eksperymentów z uzasadnionym doбором parametrów,
- poprawna interpretacja wykresów i polityk,
- spójny raport zawierający wyniki, analizę i końcowe wnioski.