

Gdzie w kursie pasuje reinforcement learning?

Trzecia część po uczeniu nadzorowanym i nienadzorowanym

Uczenie nadzorowane

Dane wejściowe mają etykiety.

Cel: przewidywanie klasy lub wartości.

Przykłady z wcześniejszych laboratoriów: KNN, drzewa decyzyjne, SVM.

Uczenie nienadzorowane

Brak etykiet.

Cel: odkrywanie struktury, grup i podobieństw.

Przykłady z wcześniejszych laboratoriów: k-means, DBSCAN.

Uczenie ze wzmocnieniem

Brak gotowych etykiet dla każdego kroku.

Agent uczy się przez interakcję ze środowiskiem i maksymalizację sumy nagród.

Typowy problem: sekwencja decyzji.

Kluczowa różnica: w RL jakość decyzji ujawnia się dopiero w czasie, a nie od razu dla pojedynczej próbki.

Podstawowy cykl RL

Agent obserwuje stan, wybiera akcję, otrzymuje nagrodę i aktualizuje strategię działania



Cel RL: maksymalizacja długoterminowej sumy nagród, a nie tylko natychmiastowego zysku w pojedynczym kroku.

- stan (state) — opis sytuacji, w której agent podejmuje decyzję,
-
- akcja (action) — ruch lub decyzja wykonana przez agenta,
-
- nagroda (reward) — sygnał jakości działania,
-
- polityka (policy) — reguła wyboru akcji,
-
- epizod (episode) — jeden pełny przebieg zadania.

W laboratorium używamy strategii epsilon-greedy: część decyzji jest losowa (eksploracja), a część wynika z najlepszej obecnie znanej akcji (eksploatacja).

Dwa algorytmy w ćwiczeniu

Porównanie Q-learning i SARSA

Q-learning (off-policy)

Aktualizacja używa najlepszej przewidywanej akcji w następnym stanie.

$$Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$$

Często prowadzi do krótszej, bardziej agresywnej polityki.

SARSA (on-policy)

Aktualizacja używa akcji rzeczywiście wybranej przez bieżącą politykę.

$$Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma Q(s',a') - Q(s,a)]$$

Często prowadzi do bezpieczniejszej i bardziej ostrożnej polityki.


oba algorytmy mogą osiągać podobny cel, ale różnią się zachowaniem podczas uczenia i kształtem finalnej trasy.

Środowisko Cliff Walking

Klasyczny benchmark dobrze pokazujący kompromis bezpieczeństwo–ryzyko

- siatka 4×12 , czyli 48 dyskretnych stanów,
-
- 4 akcje: góra, prawo, dół, lewo,
-
- start w lewym dolnym rogu, cel w prawym dolnym rogu,
-
- każdy krok ma koszt -1 ,
-
- wejście na klif: kara -100 i powrót do startu.

Dzięki temu środowisku widać, że „najkrótsza droga” nie musi być najlepsza, jeśli ryzyko kary jest wysokie.



Hiperparametry do strojenia

alpha

Szybkość uczenia.
Za duża wartość może destabilizować aktualizacje, za mała spowalnia uczenie.

gamma

Znaczenie przyszłych nagród.
Wyższe gamma promuje planowanie w dłuższym horyzoncie.

epsilon

Eksploracja vs eksploatacja.
Start, minimum i tempo zaniku wpływają na jakość polityki.

episodes




Liczba epizodów uczących.
Więcej epizodów zwykle daje lepsze dopracowanie.

Hipotezy do sprawdzenia

- Czy wolniejsze zmniejszanie epsilon poprawia finalną politykę?
-
- Czy większa alpha przyspiesza uczenie kosztem stabilności?
-
- Który algorytm częściej wybiera trasę bliżej klifu?
-
- Czy zwiększenie kary za klif wzmacnia przewagę ostrożnej polityki?

Przykładowe wyniki referencyjne

Materiał startowy do interpretacji i dyskusji



Wniosek orientacyjny: Q-learning częściej daje krótszą trasę przy klifie, a SARSA — trasę bezpieczniejszą i zwykle dłuższą.

Co ma znaleźć się w raporcie?

- krótki opis teorii RL oraz różnicy między Q-learning i SARSA,
-
- opis środowiska i sposobu kodowania stanów i akcji,
-
- tabela eksperymentów z parametrami,
-
- wykresy przebiegu uczenia oraz interpretacja,
-
- porównanie polityk końcowych i metryk,
-
- techniczne wnioski końcowe.

Minimum wykonania

Co najmniej 4 własne eksperymenty + porównanie obu algorytmów na tych samych ustawieniach.

Warto ocenić

średnią nagrodę, średnią liczbę kroków, szybkość stabilizacji wykresu oraz kształt finalnej polityki.

Gotowe pliki