



Porównanie modeli regresji



Struktura zajęć

135 minut pracy z gotowym kodem i samodzielnymi modyfikacjami



Na zajęciach studenci nie tylko uruchamiają kod, ale także zmieniają eksperyment i interpretują wynik.

train/test split

walidacja krzyżowa

metryki regresji

interpretacja wykresów

Problem i dane: Auto MPG

Regresja: przewidywanie wartości liczbowej MPG

Zmienna docelowa MPG

im większe MPG, tym
mniejsze zużycie paliwa

Cechy techniczne pojazdu

cylinders

acceleration

displacement

model_year

horsepower

origin

weight

Typowe problemy w danych

- braki danych w horsepower
- różne skale cech
- cechy kategoryczne
- potrzeba podziału train/test

Decyzja w kodzie: preprocessing jest częścią Pipeline, więc ten sam proces działa przy treningu, testowaniu i walidacji.

Pipeline eksperymentu

Stała procedura porównania modeli



Najważniejsza zasada eksperymentu:

Porównujemy algorytmy na tych samych danych, z tym samym podziałem, tym samym preprocessingiem i tymi samymi metrykami.

Jak mierzymy jakość regresji?

Model jest dobry wtedy, gdy ma mały błąd i dobrze generalizuje

MAE

średni błąd bezwzględny

łatwa interpretacja
w tych samych jednostkach co
MPG

RMSE

pierwiastek z MSE

silniej karze duże błędy
często używany do rankingu

R^2

**współczynnik
determinacji**

bliżej 1 oznacza lepsze
wyjaśnienie zmienności

**Reszta = wartość rzeczywista -
predykcja**

Dobra diagnostyka: reszty losowo wokół zera,
bez wyraźnego wzorca.

Modele liniowe: baza i regularyzacja

Regresja liniowa, Ridge i Lasso

Regresja liniowa

Zakłada zależność liniową
między cechami a MPG.
Daje czytelny model
bazowy.

Ridge = kara L2

Zmniejsza duże
współczynniki. Pomaga,
gdy cechy są skorelowane.

Lasso = kara L1

Może wyzerować część
współczynników.
Zachowuje się jak prosta
selekcja cech.

Parametr alpha kontroluje siłę regularyzacji: małe alpha = model bardziej elastyczny, duże alpha = model prostszy.

Modele nieliniowe: k-NN i SVR

Dwa różne sposoby uchwycenia złożonych zależności

k-NN Regressor

Predykcja jest średnią z najbliższych obserwacji treningowych. Model nie buduje jawnego równania, lecz korzysta z podobieństwa przypadków.

ważne: skalowanie

parametr: `n_neighbors`

SVR z jądrem RBF

SVR szuka funkcji z marginesem tolerancji błędu. Jądro RBF pozwala modelować nieliniowość bez ręcznego tworzenia nowych cech.

ważne: skalowanie

parametry: `C`, `gamma`,
`epsilon`

Modele drzewiaste

Reguły decyzyjne, uśrednianie i wzmacnianie

Drzewo decyzyjne

Dzieli dane na regiony według prostych reguł. Łatwe do interpretacji, ale może się przeuczyć.

Random Forest

Buduje wiele drzew i uśrednia ich wyniki. Zmniejsza wariancję i często daje stabilne rezultaty.

Gradient Boosting

Buduje modele sekwencyjnie. Każde kolejne drzewo poprawia błędy poprzednich.

**Sterowanie
złożonością:**

`max_depth`

`n_estimators`

`learning_rate`

`random_state`

Porównanie modeli

Ten sam problem, wiele algorytmów, wspólna procedura oceny

Ranking według RMSE_test

Niższy RMSE oznacza mniejszy typowy błąd predykcji. Program zapisuje ranking do CSV i na wykresie PNG.

Walidacja krzyżowa

5 różnych podziałów danych pozwala ocenić stabilność wyniku. Średnia i odchylenie RMSE są w tabeli.

Wykresy diagnostyczne

Predykcje vs rzeczywiste wartości oraz reszty pomagają wykrywać systematyczne błędy modelu.

Nie wybieramy modelu tylko dlatego, że „ma najwyższy wynik”. Trzeba sprawdzić błąd, stabilność, interpretowalność i koszt obliczeniowy.

Zadanie studentów

Od uruchomienia kodu do własnych wniosków

1. Uruchom

Sprawdź, czy powstał katalog wyniki_regresji oraz pliki CSV/PNG.

2. Porównaj

Wskaż najlepszy model według RMSE i zinterpretuj MAE, RMSE, R^2 .

3. Zmień

Zmień hiperparametr albo dodaj model i sprawdź wpływ na wyniki.

4. Wyjaśnij

Przygotuj krótką rekomendację modelu i uzasadnij decyzję.

Minimalny efekt końcowy:

tabela wyników + 3 wykresy + zmodyfikowany eksperyment + krótkie wnioski

Najważniejsze pytanie: który algorytm jest najlepszy dla tych danych i na jakiej podstawie to stwierdzamy?